



설계 산출물

10반 3조 | P316 김령아 | P318 김인성 | P336 이윤서 | P343 함형준 |
P344 황영준 | 346 황정현

10반 3조 | P316 김령아 | P318 김인성 | P336 이윤서 | P343 함형준 | P344 황영준 | 346 황정현

1. 기술 선정

SW | DeepSeek-V2

HW | ITME

2. 설계

3. 평가 관점 및 기준

3-1. 기술 성숙도 관점

3-1-a. 현재 기술은 실제 운용 환경에 어느 수준까지 도달했는가?

3-2. 시장성 관점

3-2-a. 시장이 이 기술의 문제 영역을 크고 빠르게 성장하는 영역으로 보는가?

3-2-b. 시장이 이 기술의 비용·성능 효과를 실질적인 경제적 가치로 인식하는가?

3-2-c. 시장이 이 기술을 실제 채택·상용화 단계까지 받아들였는가?

3-2-d. 개발 주체를 넘어선 생태계가 이 기술을 지지하고 있는가?

3. 이해관계자 관점

3-3-a. 경쟁사가 중요하게 대비하고 있는가?

3-3-b. 도입 기업이 실제로 채택하고 있는가?

3-3-c. 기존 데이터센터 인프라에 적용할 때 비용과 난이도가 낮은가?

3-3-d. 개발자 생태계가 활성화되어 있는가?

3-3-e. 투자 업계가 해당 기술에 자본을 투입하고 있는가?

3-4. 도메인 적용 관점 — 데이터센터

3-4-a. KV Cache의 메모리 부담을 얼마나 완화하는가?

3-4-b. 데이터센터 LLM 추론의 처리량과 지연시간을 개선하는가?

3-4-c. 긴 Context, 큰 Batch, 동시 사용자 증가에 대응할 수 있는가?

3-4-d. 기존 데이터센터 HW·SW 구조에 쉽게 적용할 수 있는가?

3-4-e. 추가 운영 부담보다 비용 절감 효과가 큰가?

3-4-f. 평가에 사용한 근거의 직접성과 실증 수준이 높은가?

3-4-g. 제안 주체와 독립된 제3자가 기술을 재현하거나 검증했는가?

3-4-h. 평가 워크로드가 실제 데이터센터 LLM Serving 환경을 대표하는가?

3-4-i. 근거가 최신이며 외부에서 검증 가능한 형태로 공개되어 있는가?

종합의견

4. 그래프 설계

공통 State 설계

Graph 설계

5. 평가 보고서 목차

1. 기술 선정

SW | DeepSeek-V2

- 왜 선택했는지: MLA와 transformer 아키텍처 혁신.
 - 기존 MHA는 context가 길어짐에 따라 KV cache가 선형적으로 늘어남. DeepSeek는 MLA 구조를 적용해 KV cache의 토큰 당 저장해야 할 차원을 크게 줄임. (MLA가 MHA 대비 KV cache를 93.3% 줄였다고 보고)
 - MHA는 각 head의 K/V를 독립적으로 KV cache에 저장. 반면 MLA는 각 head의 K/V 정보가 독립적으로 존재할 필요가 없다고 보고, 여러 head의 K/V를 공통 저차원 latent vector로 joint compression하여 저장함으로써 KV cache를 크게 줄임.
 - 다른 SW 방법론들은 inference시에 복원이 필요하지만, DeepSeek의 MLA는 latent vector 그대로 사용하면서 attention 계산을 수행함 → 아키텍처 구조 혁신 덕분(up-projection을 query쪽으로 흡수)

$$\begin{aligned} q^T k &= q^T W_{UK} c_{KV} \\ &= (W_{UK}^T q)^T c_{KV} \end{aligned}$$

- 단점: RoPE를 그대로 압축된 벡터에 적용하면 안되기 때문에 Decoupled RoPE를 도입해서 위치 정보를 별도로 유지한다. 이것도 캐시해야함.
- KV cache memory는 적어지지만 계산량과 연산 복잡도는 늘어남. 압축되면서 KV 정보의 손실 가능성. 모델 구조, 학습 복잡도가 높아짐. head간의 독립성이 떨어짐.
- 선택하지 않은 이유
 - TurboQuant : TurboQuant는 정량적인 압축 효과를 평가하기 좋은 기술이지만, KV cache 생성 이후의 양자화에 초점이 맞춰져 있다. 반면 DeepSeek-V2 MLA는 Attention 구조 단계에서 KV cache 발생량 자체를 줄이는 접근이어서 기술 구조, 시스템 적용성, 성능, 도입 복잡성 등 다양한 관점에서 평가할 요소가 더 많다고 판단했다.

- KIVI : 직관적이라는 장점은 있으나 구현이 너무 단순해서 많은 관점을 보는 의미가 없을 것 같았음.

HW | ITME

- 왜 선택했는지
 - HW 진영의 논리를 가장 순수하게 구현한 사례
 - 데이터 자체를 줄이지 않고 "답을 곳"만 바꿔서 푸는 접근.
 - **제시된 HW 후보 3건 중** InfiniGen은 기존 호스트 메모리 위 오프로딩 최적화에 가깝고, PIM은 메모리 배치를 넘어 연산 이동까지 포함해 본 분석 범위를 벗어남. **압축 없이 이동만으로 푸는 접근은 ITME가 가장 순수함.**
 - 병목 해결을 위한 Trade-Off가 수치적으로 드러남
 - HW 확장도 공짜가 아니라는 걸 논문이 직접 공개
 - DRAM 캐시를 2배로 키우면 온칩 SRAM이 86.7% 폭증해 포기, 대역폭 정합을 위한 채널 구성, 읽기/쓰기 경합. "공간을 넓히자"는 주장의 실제 대가를 분석할 근거가 있음
 - **관점 간 충돌이 기술 안에 내장되어 있음**
 - 핵심 디바이스는 FPGA 프로토타입인 반면 성능은 양산 부품으로 구성한 별도 플랫폼으로 주장함(공개 정보 기반 TRL 추정 5 전후). 도메인별 쟁점도 뚜렷해, 하나의 기술이 관점에 따라 다르게 읽히는 과제 취지에 부합함.
 - **이해관계자 대립 구도의 출발점을 1차 자료에서 확보할 수 있음**
 - 논문이 NVIDIA를 "비싼 DPU"로, Samsung CMM-H를 "대역폭 제약"으로 직접 겨냥·평가함. 단 이는 **SK hynix의 일방적 주장이므로, 상대 진영의 반론을 별도 검색으로 대칭 수집하는 것을 전제로 함.**

⇒ 기술적으로 우월해서가 아니라, HW 진영이 병목을 어떤 자원과 교환하는지를 가장 선명하게 보여주고, 관점별 평가가 가장 크게 갈리는 사례이기 때문에 채택하였습니다 !!

- 선택하지 않은 이유
 - InfiniGen
 - 핵심 아이디어의 간결성과 그 구현의 복잡성(중요한 특징을 어떻게 정의할지 등) 사이의 격차가 지나치게 벌어짐
 - gpu 메모리로 가져오는 속도가 병목인데 ram 쪽 메모리가 남는 경우라는 두 조건이 모두 만족되는 한정적인 경우에만 적용 가능. 그냥 gpu가 부족한 일반적인 경우에 쓰기는 어려움
 - PIM/CXL

- recall로 인한 병목을 제거하지만, PIM에서의 연산속도는 GPU보다 느리다는 한계가 존재.
- 결과의 경우 실제 칩이 아닌 사이클 수준의 시뮬레이터에서 진행되어 낙관적 전망의 수치일 가능성이 있다.
- 논문 내 비교대상이 A100(구세대)이기에 H100/B200등 최신 스택과 비교했을 때 개선 폭이 줄어들 수 있다.

2. 설계

- 기술 선정 방식 : 팀 내부의 조사와 논의로 결정
- Agent 설계 및 RAG 적용 대상

에이전트	역할	RAG 여부	내용	담당
 기술 조사 에이전트	기술 2건의 원문 확보 핵심 추출	O	원문에서 기술 개요, 범위, 한계 추출	황영준
 시장 평가 에이전트	시장성, 채택 현황 조사	O	시장 규모, 상용화/채택 사례, 성장 전망 검색	김인성
 이해관계자 평가 에이전트	관계자별 반응 조사	X	경쟁사 반응, 개발자 평가, 투자/업계 시각 등 검색	이윤서
 도메인 평가 에이전트	적용 도메인별 적합성	O	데이터센터, 온디바이스, 클라우드 서버 등에서의 평가	김령아
 평가 종합 에이전트	관점별 의견 종합 및 비교	X	관점 간 일치/불일치 의견 기반으로 의견 종합	함형준
 보고서 생성 에이전트	평가 보고서 생성	X	단계별 내용을 연결하여 보고서 생성	황정현

- Embedding 모델 선정 : BGE-M3 (hybrid)
 - 기술 조사 에이전트에서 활용될 논문이 영어와 중국어 → 영어/중국어 처리에 강해야 함.
 - 논문에 표가 많기 때문에 구조성을 잘 반영해야 함.
 - 논문의 계층적인 논리 구조를 잘 반영해야 함.
 - 그 외로 고려했던 것 (ColPali)
 - PDF를 이미지 상태로 입력받아 그대로 임베딩함
 - 논문의 표와 figure의 시각적 정보를 보존하는데는 강점이 있어보임
 - 근데 이미지를 patch로 쪼개서 임베딩하는만큼 저장공간과 연산비용이 훨씬 비싸다.

⇒ 3B 파라미터로 무거운 모델이어서 최종 탈락

3. 평가 관점 및 기준

선정 도메인 : 데이터센터

- 데이터센터는 대규모 LLM 추론이 이루어지고, 메모리 용량, 처리량, 비용 효율이 중요한 환경이기 때문에 선정하였다. 과제 가이드에서도 데이터센터 & 클라우드를 대규모 또는 비용 민감도메인으로 제시하고 있다.
- 또한 DeepSeek-V2 MLA는 KV cache 자체를 저차원 잠재 표현으로 압축하는 SW 접근이고, ITME는 CXL-Hybrid Memory를 이용해 메모리 계층을 확장하는 HW 접근이므로, 동일한 데이터센터 LLM 추론 환경에서 두 기술의 메모리 효율성, 추론 성능, 확장성, 인프라 적용성 및 운영 및 비용 효율성의 trade-off를 비교하기 적합하다.

4가지 관점 별 평가 대상 및 기준 정의

- 각 평가 항목은 평가 질문 → 주요 확인 근거 → 점수표 → 예외 규칙의 동일한 형식으로 구성한다.
- 별도 설명이 없는 한 높은 점수일수록 해당 관점에서 긍정적인 평가를 의미한다.
- 정량 수치는 출처, 기준 시점, 비교 기준선(baseline)이 확인된 경우에만 인정한다.
- 기술별 특성을 보존하기 위해 관점별 척도는 강제로 통일하지 않는다.
 - 기술 성숙도: TRL 1~9
 - 시장성: 100점
 - 이해관계자: 항목별 1~5점, 총점 100점 환산
 - 도메인 적용성: 항목별 1~5점, 가중 평균
- 조사했지만 근거를 확인하지 못한 경우 **NOT_VERIFIED** 로 기록

3-1. 기술 성숙도 관점

3-1-a. 현재 기술은 실제 운용 환경에 어느 수준까지 도달했는가?

- **주요 확인 근거:** 논문, 학회 발표, 특허, 실험실 검증, 통합 프로토타입, 유사 환경 시연, 실제 운용 환경 시연, 고객사 샘플 공급, 양산 발표, 상용 납품

TRL	평가 기준
1	기초 원리가 관찰된 아이디어·이론 수준

TRL	평가 기준
2	기술 개념이 정립되고 적용 가능성을 검토한 수준
3	개념을 검증하고 실험실 수준에서 실증한 단계
4	부품 또는 구성요소를 실험실 환경에서 통합·검증한 단계
5	부품 또는 구성요소를 실제와 유사한 환경에서 통합·검증한 단계
6	시스템 또는 하위 시스템을 실제 환경과 유사한 조건에서 시연한 단계
7	시스템 시제품을 실제 운용 환경에서 시연한 단계
8	시스템이 완성되었고 양산 적합성 검증까지 완료한 단계
9	실제 운용과 상용 양산·납품이 이루어진 단계

• 판정 시 주의사항

- TRL 1~3은 논문·학회 발표·특허 등 공개 정보가 비교적 풍부하다.
- TRL 4~6은 수율, 공정 파라미터, 실제 성능 수치가 영업 비밀에 해당하여 공개 정보와 실제 수준의 차이가 가장 크게 발생할 수 있다.
- TRL 7~9는 고객사 샘플 공급, 양산 발표, 실적 공시 등을 통해 일부 확인할 수 있지만 구체적인 수율과 원가는 공개되지 않을 수 있다.
- KV Cache 기술은 논문 발표와 실제 채택 사이에 시차가 있으므로, 결과에 **공개 정보 기반 추정**임을 명시한다.
- 구성요소의 성숙도와 전체 시스템의 성숙도가 다를 경우 각각 평가하며, 전체 기술의 TRL을 구성요소의 최고 단계와 동일시하지 않는다.

3-2. 시장성 관점

배점 및 환산 규칙

- 4개 항목을 1~5점으로 평가하며 동일 비중으로 반영한다. $100\text{점 환산 총점} = \text{획득 점수 합계} \div 20 \times 100$
- 각 항목에는 점수와 별도로 **근거 신뢰도 태그**(강함/보통/약함/NOT_VERIFIED)를 함께 기록한다. 이 태그는 총점에 합산하지 않고, 보고서에서 해당 판단의 확신 수준을 표시하는 용도로만 쓴다.
- **NOT_VERIFIED**: 조사했지만 근거를 확인하지 못한 경우.

3-2-a. 시장이 이 기술의 문제 영역을 크고 빠르게 성장하는 영역으로 보는가?

- **주요 확인 근거**: TAM·SAM 또는 관련 상위 시장 규모, CAGR / Context Length·동시성·Agent·RAG 등 워크로드 증가 지표
- **주의 사항**: 시장 범주를 구조적으로 정의할 수 없으면 N/A. 서로 다른 시장 범주에 있는 기술 간 시장 규모를 직접 비교하지 않는다.

점수	평가 기준
5	대상(또는 관련 상위) 시장 규모가 크고 CAGR이 두 자릿수 이상인 고성장 구간이며, 관련 워크로드 지표도 뚜렷한 증가 추세로 나타남
4	시장 규모가 중견 이상이고 성장세가 뚜렷하며, 워크로드 증가 신호도 함께 관찰됨
3	특정 세그먼트에서는 성장이 뚜렷하나 전체 시장 규모·성장률은 중간 수준이거나 워크로드 연결이 간접적임
2	시장 규모가 작거나 성장세가 완만하며 수요 증가 신호가 약함
1	시장이 형성되지 않았거나 정체·위축 추세이며 수요 증가 신호가 없음

3-2-b. 시장이 이 기술의 비용·성능 효과를 실질적인 경제적 가치로 인식하는가?

- **주요 확인 근거:** 메모리 감소량, 지연시간, 처리량, GPU 수, \$/token, TCO 등 baseline 대비 개선폭
- **주의 사항:** KV Cache 감소량을 비용 감소량과 동일시하지 않는다. 서로 다른 baseline 수치를 직접 비교하지 않는다.

점수	평가 기준
5	복수 차원(메모리·지연·처리량 등)에서 baseline 대비 수 배 이상 개선이 확인되고, TCO·\$/token 등 구체적 비용 지표까지 이어짐
4	특정 차원에서 뚜렷한 개선이 있으나 비용 지표까지는 연결되지 않음
3	개선 효과는 있으나 특정 조건·환경에 한정되거나 규모가 제한적임
2	개선 효과가 미미하거나 정성적 언급 수준에 그침
1	비용·경제적 효과가 확인되지 않음

3-2-c. 시장이 이 기술을 실제 채택·상용화 단계까지 받아들였는가?

- **주요 확인 근거:** 실제 상용 서비스·제품, 독립적인 도입 주체, 하이퍼스케일러 발표, Pilot·PoC, 공개 서비스 적용
- **주의 사항:** 대상이 구조적으로 없으면 N/A. 논문·프로토타입은 상용화 사례로 분류하지 않는다.

점수	평가 기준
5	서로 독립적인 복수 주체가 실제 상용 서비스·제품에 적용 중임
4	최소 1건의 상용 적용, 또는 주요 기업·하이퍼스케일러의 채택이 확인됨
3	고객 Pilot·PoC 또는 공개 서비스 적용 단계에 있음
2	제품 로드맵·발표·논문·프로토타입 수준에 머물러 있음
1	채택·상용화 움직임이 없음

3-2-d. 개발 주체를 넘어선 생태계가 이 기술을 지지하고 있는가?

- **주요 확인 근거:** 제3자 Serving Framework 지원, 커뮤니티 포트, 독립 구현 / 표준화 활동, 산업 참여 / 타 KV Cache 기술과의 실제 결합 사례
- **주의 사항:** 결합 가능성은 이론적 언급이 아니라 실제 사례·연구 기준으로 판단한다.

점수	평가 기준
5	개발 주체 외 2개 이상 조직의 공식 지원 또는 표준화·산업 참여가 확인되고, 타 기술과의 실제 결합 사례가 2건 이상임
4	개발 주체 외 1개 조직의 지원, 또는 표준화·산업 참여 중 하나가 확인되고 결합 사례가 1건 이상임
3	제3자 구현·커뮤니티 포트·독립 평가 버전이 존재하거나 결합 가능성 연구가 존재함
2	원 개발 조직의 구현만 존재하거나 표준·확장 가능성이 단순 언급 수준임
1	생태계 지지 근거가 없음

3. 이해관계자 관점

- 배점 및 환산 규칙
 - 각 항목을 1~5점으로 평가하며, 5개 항목은 동일한 비중으로 반영한다.
 - $100\text{점 환산 총점} = \text{획득 점수 합계} \div 25 \times 100$

3-3-a. 경쟁사가 중요하게 대비하고 있는가?

- **주요 확인 근거:** 경쟁사 공식 발표, 제품 출시, 특허, 논문, 기술 블로그, 로드맵, 벤치마크, PoC

점수	평가 기준
1	경쟁사 또는 경쟁 기술 진영의 반응이 거의 없음
2	기사, 인터뷰, 기술 블로그 등에서 단순 언급됨
3	기술 비교, 벤치마크 또는 관련 연구가 등장함
4	경쟁사가 유사 기능·대응 기술을 개발하거나 PoC를 진행함
5	다수 경쟁사가 실제 제품·서비스 또는 핵심 로드맵에 대응 기술을 반영함

3-3-b. 도입 기업이 실제로 채택하고 있는가?

- **주요 확인 근거:** 고객 사례, 기업 공식 발표, 구축 사례, 기술 도입 기사, 서비스 적용 여부, Production 적용

점수	평가 기준
1	기업의 도입 사례가 확인되지 않음

점수	평가 기준
2	기술에 대한 관심·검토 사례가 존재함
3	PoC, 파일럿 또는 내부 테스트 사례가 존재함
4	실제 서비스 또는 일부 업무에 적용되고 있음
5	다수 기업이 Production 환경이나 핵심 업무에 본격적으로 적용하고 있음

3-3-c. 기존 데이터센터 인프라에 적용할 때 비용과 난이도가 낮은가?

- **주요 확인 근거:** 모델 구조 변경, 재학습, 신규 장비 도입, 서버 인프라 재구축, 기존 시스템 호환성, 전문 인력, 기술 안정성, 규제·보안
- **판정 시 주의사항:** MLA는 해당 구조를 채택한 모델을 사용하거나 모델 구조 변경과 재학습이 필요할 수 있는지를 확인한다. ITME는 새로운 메모리 계층 추가와 서버 인프라 개조에 필요한 시간·비용을 확인한다.

점수	평가 기준
1	높은 비용, 규제, 전문 인력, 시스템 변경 등 중대한 장벽이 다수 존재함
2	도입을 위해 상당한 인프라·아키텍처 변경이 필요함
3	일정 수준의 기술 인력과 시스템 변경이 필요함
4	기존 시스템에 비교적 쉽게 통합할 수 있고 주요 장벽이 제한적임
5	낮은 비용과 적은 코드·인프라 변경만으로 쉽게 도입할 수 있음

3-3-d. 개발자 생태계가 활성화되어 있는가?

- **주요 확인 근거:** GitHub contributor·commit, 공식 SDK, 주요 프레임워크 지원, issue 활동, 문서 수준, 실제 적용 사례

점수	평가 기준
1	연구 코드 수준이며 문서·구현체가 거의 없음
2	오픈소스 구현체는 있으나 활용 사례와 문서가 제한적임
3	공식 문서와 라이브러리가 존재하고 지속적으로 개발되고 있음
4	주요 프레임워크에서 지원되며 다수의 실제 프로젝트에서 활용됨
5	사실상 업계 표준 수준으로 주요 프레임워크·플랫폼에서 기본 지원됨

3-3-e. 투자 업계가 해당 기술에 자본을 투입하고 있는가?

- **주요 확인 근거:** 투자 금액, 투자 건수, 전년 대비 증가율, 관련 스타트업 수, VC 포트폴리오, M&A, Big Tech의 전략적 투자·CAPEX

점수	평가 기준
1	관련 투자 사례가 거의 없음
2	초기 투자 또는 일부 스타트업 투자가 발생함
3	관련 스타트업과 투자 건수가 지속적으로 증가하고 있음
4	대규모 VC 투자, M&A, Big Tech의 전략적 투자가 다수 발생함
5	독립적인 시장 영역으로 형성되어 지속적인 대규모 자본이 유입되고 있음

3-4. 도메인 적용 관점 — 데이터센터

- 가중치 구조

그룹	평가 항목	가중치
A. 도메인 적합성	4.1 메모리 효율성	0.15
	4.2 추론 성능	0.16
	4.3 확장성	0.14
	4.4 인프라 적용성	0.13
	4.5 운영·비용 효율성	0.12
B. 근거 신뢰도	4.6 근거 등급·실증 성숙도	0.10
	4.7 독립 검증	0.08
	4.8 워크로드 대표성	0.07
	4.9 최신성·공개성	0.05
합계		1.00

- NOT_VERIFIED** 처리 및 가중 점수 산정
 - 문헌에 근거가 없으면 임의의 점수를 주지 않고 **NOT_VERIFIED** 로 표기한다.
 - NOT_VERIFIED** 항목은 가중치와 점수 계산에서 제외한다.
 - coverage** 가 0.6 미만이면 최종 판정을 보류하고 **근거 불충분** 으로 결론낸다.

가중 점수	Coverage	판정
4.0 이상	0.8 이상	적합 — 근거 충분
4.0 이상	0.6 이상 0.8 미만	적합 — 근거 보강 필요
3.0 이상 4.0 미만	0.6 이상	조건부 적합
2.0 이상 3.0 미만	0.6 이상	제한적 적합
2.0 미만	0.6 이상	부적합
해당 없음	0.6 미만	판정 보류 — 근거 불충분

3-4-a. KV Cache의 메모리 부담을 얼마나 완화하는가?

- **주요 확인 근거:** KV 점유량, 압축률, 오프로드 비율, 유효 메모리 용량 배수, HBM 부담

점수	평가 기준
5	KV 점유를 정량적으로 대폭 경감하며 압축률·오프로드 비율·유효 용량 배수 중 하나 이상이 명시됨
4	경감 효과를 수치로 제시하지만 특정 모델·설정에 한정됨
3	경감 방향은 명확하지만 수치가 부분적이거나 간접적임
2	정성적 주장만 존재함
1	HBM 부담 경감 근거가 없거나 오히려 증가함

3-4-b. 데이터센터 LLM 추론의 처리량과 지연시간을 개선하는가?

- **주요 확인 근거:** 처리량, 지연시간, 메모리 대역폭, 데이터 접근 지연, 비교 기준선

점수	평가 기준
5	처리량 개선을 정량적으로 보고하고 지연시간 악화가 없음도 함께 확인됨
4	처리량 개선은 정량적으로 확인되지만 지연시간 영향은 보고되지 않음
3	처리량 개선과 지연시간 페널티가 trade-off로 공존함
2	성능 영향을 메모리 대역폭·지연 등 간접 지표로만 추정할 수 있음
1	성능 저하가 명시되거나 관련 근거가 전혀 없음

3-4-c. 긴 Context, 큰 Batch, 동시 사용자 증가에 대응할 수 있는가?

- **주요 확인 근거:** Context Length, Batch Size, 동시 사용자 수에 대한 개별 정량 실험

점수	평가 기준
5	Context Length, Batch Size, 동시 사용자 등 3개 축 모두에 정량 근거가 존재함
4	2개 축에 정량 근거가 존재함
3	1개 축에 정량 근거가 존재함
2	확장 방향만 제시되고 수치는 없음
1	확장 한계가 드러나거나 근거가 없음

3-4-d. 기존 데이터센터 HW·SW 구조에 쉽게 적용할 수 있는가?

- **주요 확인 근거:** 추가 장비, 표준 인터페이스, 무중단·점진적 증설, 모델 재학습, Serving Stack 수정, 벤더·환경 종속성

점수	평가 기준
5	추가 장비가 필요 없고 기존 Serving Stack을 수정하지 않고 적용할 수 있음

점수	평가 기준
4	표준 인터페이스를 기반으로 점진적·무중단 증설이 가능함
3	추가 장비 또는 재학습·Stack 수정 중 하나가 필요함
2	추가 장비와 재학습·Stack 수정이 모두 필요하거나 특정 벤더·환경에 종속됨
1	전용 하드웨어와 전면 재구성이 필요함

3-4-e. 추가 운영 부담보다 비용 절감 효과가 큰가?

- **주요 확인 근거:** 압축·복원·재계산 오버헤드, 링크 트래픽, 전송 지연, 대역폭 점유, 부가 자료 구조·메타데이터, 스케줄러·할당기·티어링 정책, TCO

점수	평가 기준
5	오버헤드가 작다는 점이 정량적으로 확인되고 비용 절감 근거도 존재함
4	오버헤드가 정량적으로 확인되지만 비용 절감 근거는 정성적임
3	오버헤드가 존재하지만 관리 가능한 수준임이 논증됨
2	오버헤드가 언급되지만 규모를 확인할 수 없음
1	상당한 오버헤드·복잡성 증가가 확인되거나 비용 논의가 전혀 없음

3-4-f. 평가에 사용한 근거의 직접성과 실증 수준이 높은가?

- **주요 확인 근거:** 피어리뷰 논문의 직접 측정치, 시뮬레이션·모델링, 벤더 스펙시트·백서, 2차 인용·블로그·추론
- **판정 시 주의사항:** 해당 기술을 평가하는 데 사용한 근거 중 가장 자주 등장하는 등급을 적용한다.

점수	근거 등급	평가 기준
5	E3	피어리뷰 논문에서 직접 측정한 수치
4	E2	논문의 시뮬레이션 또는 모델링 결과
2	E1	직접 측정이 없는 벤더 스펙시트 또는 백서
1	E0	2차 인용, 블로그 또는 추론

3-4-g. 제안 주체와 독립된 제3자가 기술을 재현하거나 검증했는가?

- **주요 확인 근거:** 제3자 재현 논문, 독립 벤치마크, 제안자 외 기관의 검증 자료

점수	평가 기준
5	제안자 외 제3자가 재현하거나 검증한 문헌이 존재함
3	제안자 논문만 존재함

점수	평가 기준
1	단일 비공식 자료만 존재함

3-4-h. 평가 워크로드가 실제 데이터센터 LLM Serving 환경을 대표하는가?

- **주요 확인 근거:** 모델 규모, 요청 패턴, 동시성, Context Length, Batch Size, 실제 Serving Stack, 실험 규모

점수	평가 기준
5	평가 환경이 데이터센터 LLM Serving 환경과 직접 부합함
3	환경은 유사하지만 스케일 또는 조건에 차이가 있음
1	실제 Serving과 무관한 Micro-benchmark만 존재함

3-4-i. 근거가 최신이며 외부에서 검증 가능한 형태로 공개되어 있는가?

- **주요 확인 근거:** 자료 발표 시점, 코드·모델 공개 여부, 접근 가능성, 재현 가능성

점수	평가 기준
5	최근 자료이며 코드·모델이 공개되어 검증할 수 있음
3	자료는 존재하지만 코드·모델 또는 세부 정보가 비공개임
1	자료가 오래되었거나 접근할 수 없음

종합의견

- 3-1 ~ 3-4번 관점들의 의견을 종합하되, 관점 간 상충 지점이 명시적으로 드러나도록 함


4. 그래프 설계

공통 State 설계

State Key	Type (예시, 수정 가능)	생성 주체	사용 주체	내용
background_facts	<code>dict[str, str]</code>	초기 입력	보고서 작성 Agent	분석 배경 작성: KV cache 병목의 근거(메모리증가량, 컨텍스트 길이의 추세 등)
selected_technologies	<code>dict[str, str] — {sw: 기술명, hw: 기술명}</code>	초기 입력	전체 Agent	SW: DeepSeek-V2 MLA, HW: ITME

State Key	Type (예시, 수정 가능)	생성 주체	사용 주체	내용
target_domain	str	초기 입력	도메인 평가 Agent	선정 도메인: 데이터센터
technical_result	dict[str, {summary: str, performance: list[str], limitations: list[str], evidence: list[str]}]	기술 조사 Agent	TRL/시장/이해관계자/도메인 관점 평가	두 기술의 구조, 성능, 범위, 한계 및 원문 근거
trl_result	dict[str, {trl_value: int, rationale: str, evidence: list[str]}]	TRL 평가 Node	평가 종합 Agent	기술별 TRL 추정 값과 판단 근거
market_result	dict[str, {score: float, rationale: str, evidence: list[str]}]	시장 평가 Agent	평가 종합 Agent	시장 규모, 채택 현황, 생태계 평가 결과
stakeholder_result	dict[str, {score: float, rationale: str, evidence: list[str]}]	이해관계자 평가 Agent	평가 종합 Agent	경쟁사, 도입기업, 개발자, 투자업계 관점 평가
domain_result	dict[str, {score: float, rationale: str, evidence: list[str]}]	도메인 평가 Agent	평가 종합 Agent	데이터센터 기준 기술별 적용 적합성 평가
evaluation_result	{agreements: list[str], disagreements: list[str], tradeoffs: list[str], implications: list[str]}	평가 종합 Agent	보고서 생성 Agent	4가지 관점의 일치 및 불일치 및 trade-off 종합
references	list[dict]	조사/평가 Agent	평가 종합, 보고서 Agent	실제 평가에 사용한 출처 목록
final_report	str	보고서 생성 Agent	최종 Output	최종 다관점 평가 보고서

Graph 설계



먼저 기술 조사 Agent가 DeepSeek-V2 MLA와 ITME의 원문을 기반으로 기술 구조, 성능, 범위 및 한계를 추출한다.

이후 기술 성숙도(TRL), 시장성, 이해관계자, 도메인 관점의 평가를 병렬(Fan-out)로 수행한다. 각 평가 결과는 trl_result, market_result, stakeholder_result, domain_result와 같이 서로 다른 State key에 저장한다.

모든 평가가 완료되면 평가 종합 Agent에서 결과를 Fan-in하여 관점 간 일치 및 불일치 및 trade-off를 도출하고, 보고서 생성 Agent가 이를 최종 평가 보고서로 구성한다.

5. 평가 보고서 목차

SUMMARY

- 전체 평가 보고서의 핵심 요약

1. 분석 배경

2. 기술 선정

3. 기술 개요

3.1 DeepSeek-V2 MLA

3.2 ITME

4. 관점별 평가

4.1 기술 성숙도 관점 — TRL

4.2 시장성 관점

4.3 이해관계자 관점

4.4 도메인 적용 관점 — 데이터센터

5. 종합 평가 및 시사점

6. 한계점

REFERENCE